

Caras de Chernoff

Las personas reaccionan a las caras. Chernoff (1973) sugiere representar observaciones *p*-dimensionales como una cara bidimensional cuyas características (forma de la cara, curvatura de la boca, longitud de la nariz, tamaño del ojo, posición de la pupila, etc.) son determinadas por las mediciones de *p* variables (Johnson y Wichern, 2007)

Las caras de Chernoff son un método para representar datos multivariados en forma de caras animadas. Su principal uso es mejorar la capacidad del usuario para detectar y comprender un fenómeno importante. Otras ventajas incluyen la facilidad de monitorear la sensibilidad de las variables entre sí, rápida identificación de variables clave y la detección de tendencias longitudinales. Por el contrario, algunas desventajas que este método presenta es que los valores extremos tienen un profundo efecto sobre la apariencia de las caras y consecuentemente, generar una mala interpretación del fenómeno (Raciborski, 2009).

Caras de Chernoff en R.

La función *faces* de la librería *aplpack* (Wolf, 2019) genera las caras de Chernoff en R. Su sintaxis es:

```
faces(xy, which.row, fill = FALSE, face.type = 1, nrow.plot,
ncol.plot, scale = TRUE, byrow = FALSE, main, labels, print.info =
TRUE, na.rm = FALSE, ncolors = 20, col.nose = rainbow(ncolors),
col.eyes = rainbow(ncolors, start = 0.6, end = 0.85), col.hair =
terrain.colors(ncolors), col.face = heat.colors(ncolors), col.lips
= rainbow(ncolors, start = 0, end = 0.2), col.ears = rainbow(ncolors,
start = 0, end = 0.2), plot.faces = TRUE, cex = 2)
```

Sus principales argumentos son:

<code>xy</code>	Es la matriz de datos <code>xy</code> .
<code>which.row</code>	Define una permutación de las filas de la matriz de entrada.
<code>fill</code>	Si <code>fill==TRUE</code> , solo se transforman los primeros números de columnas de <code>xy</code> .
<code>facettype</code>	un número entero entre 0 y 2, 0=caras de dibujo lineal, 1= elementos de las caras pintados, 2= caras de Santa Claus dibujadas.

A diferencia de R, la función *chernoff* en STATA permite asignar de forma manual cada atributo facial a una determinada variable, mientras que, en R, estas variables son asignadas con base en la matriz de datos `xy`.

Aplicaciones

a) Utilidades públicas

Para ilustrar el uso de las caras de Chernoff para propósitos de clasificación se replicó el ejemplo de las empresas de servicios públicos de Johnson y Wichern (2007). Los datos se muestran en la *Tabla 1* y la descripción de cada variable en la *Tabla 2*.

Tabla 1. Datos de utilidades públicas obtenidos de Johnson y Wichern (2007).

Id	company	state	cluster	covr	rtn	coast	load	grow	sale	nuke	fuel	label
1	Arizona Public	AZ	C2	1.06	9.2	151	54.4	1.6	9077	0	0.63	1-AZ
2	Boston Edison	MA	C6	0.89	10.3	202	57.9	2.2	5088	25.3	1.56	2-MA
3	C. Louisiana El.	LA	C2	1.43	15.4	113	53	3.4	9212	0	1.06	3-LA
4	Comm. Edison	IL	C1	1.02	11.2	168	56	0.3	6423	34.3	0.7	4-IL
5	Con. Edison	NY	C5	1.49	8.8	192	51.2	1	3300	15.6	2.04	5-NY
6	Florida Power	FL	C3	1.32	13.5	111	60	-2.2	11127	22.5	1.24	6-FL
7	Hawaiian El.	HI	C7	1.22	12.2	175	67.6	2.2	7642	0	1.65	7-HI
8	Idaho Power	ID	C4	1.1	9.2	245	57	3.3	13082	0	0.31	8-ID
9	Kentucky Utils	KY	C2	1.34	13	168	60.4	7.2	8406	0	0.86	9-KY
10	Madison Gas	WI	C1	1.12	12.4	197	53	2.7	6455	39.2	0.62	10-WI
11	Nevada Power	NV	C4	0.75	7.5	173	51.5	6.5	17441	0	0.77	11-NV
12	New England El.	NE	C6	1.13	10.9	178	62	3.7	6154	0	1.9	12-NE
13	Northern States	MN	C1	1.15	12.7	199	53.7	6.4	7179	50.2	0.53	13-MN
14	Oklahoma Gas	OK	C2	1.09	12	96	49.8	1.4	9673	0	0.59	14-OK
15	Pacific Gas	CA	C7	0.96	7.6	164	62.2	-0.1	6468	0.9	1.4	15-CA
16	Puget Sound	WA	C4	1.16	9.9	252	56	9.2	15991	0	0.62	16-WA
17	San Diego Gas	CA	C6	0.76	6.4	136	61.9	9	5714	8.3	1.92	17-CA
18	The Southern Co.	AZ	C2	1.05	12.6	150	56.7	2.7	10140	0	1.11	18-AZ
19	Texas Utils	TX	C2	1.16	11.7	104	54	-2.1	13507	0	0.64	19-TX
20	Wisconsin El.	WI	C1	1.2	11.8	148	59.9	3.5	7287	41.1	0.7	20-WI
21	United Illum	CT	C5	1.04	8.6	204	61	3.5	6650	0	2.12	21-CT
22	Virginia El.	VA	C3	1.07	9.3	174	54.3	5.9	10093	26.6	1.31	22-VA

Tabla 2. Descripción de las variables.

Variable		Descripción
covr	X ₁	Índice de cobertura de cargo fijo, ingresos/deuda
rtrn	X ₂	Tasa de rendimiento del capital
cost	X ₃	Costo por kW de capacidad instalada
load	X ₄	Factor de carga anual
grow	X ₅	Crecimiento máximo de la demanda de kWh de 1974 a 1975
sale	X ₆	Ventas, uso de kWh por año
nuke	X ₇	Porcentaje nuclear
fuel	X ₈	costos totales de combustible, centavos por kWh

Para facilitar la agrupación por clusters tal como lo muestra Raciborski (2009), se agregó una columna adicional que identificará cada registro al cluster perteneciente. Asimismo, se agregó una columna de etiquetas para facilitar la identificación en el gráfico de salida.

El código utilizado en R para graficar las caras de Chernoff sin agrupamiento en clusters fue el siguiente:

```
#librerias
library(aplpack)
library(readr)

#Conectar folder
setwd("C:/Users/zaira/Documents/01 - Doctorado PCF/Otoño 2020/Analisis
multivariado/Tareas_ZRPV/Tarea1")

#Public utility data
datos<-read.csv("public_utility_data.csv",header = TRUE)
summary(datos)

##Caras de Chernoff sin clusters
?faces
cher<-faces(datos[5:12],main = "Chernoff faces",labels=datos$label,cex = 0.9,
face.type=0)
```

La asignación de atributos faciales en R para cada variable se muestra en la *Tabla 3*. El gráfico de salida se muestra en la *Figura 1*.

Tabla 3. Asignación de atributos faciales por variable en R.

Variable	Características de la cara
covr	Altura de la cara, altura del cabello
rtrn	Ancho de la cara, ancho del cabello
cost	Estructura de la cara, estilo del cabello
load	Altura de la boca, altura de la nariz
grow	Ancho de la boca, ancho de la nariz
sale	Sonrisa, ancho de orejas
nuke	Altura de los ojos, altura de oreja
fuel	Ancho de los ojos

Chernoff faces




Figura 1. Caras de Chernoff sin agrupamiento.

En complemento, los autores agruparon las compañías de acuerdo a su localización geográfica con el objetivo de facilitar la interpretación de las caras. Para construir los cluster en R se separó la base de datos completa en función de la columna “cluster” mediante el siguiente script:

```
##Caras de Chernoff en clusters
cluster1<-datos[datos$cluster=="C1",]
cluster2<-datos[datos$cluster=="C2",]
cluster3<-datos[datos$cluster=="C3",]
cluster4<-datos[datos$cluster=="C4",]
cluster5<-datos[datos$cluster=="C5",]
cluster6<-datos[datos$cluster=="C6",]
cluster7<-datos[datos$cluster=="C7",]

cher_c1<-faces(cluster1[5:12],main = "Cluster 1",labels=cluster1$label,cex =
0.9,ncol.plot = 1,nrow.plot = 4,face.type = 0)
cher_c2<-faces(cluster2[5:12],main = "Cluster 2",labels= cluster2$label,cex =
0.9,ncol.plot = 1,nrow.plot = 6,face.type = 0)
cher_c3<-faces(cluster3[5:12],main = "Cluster 3",labels= cluster3$label,cex =
0.9,ncol.plot = 1,nrow.plot = 2,face.type = 0)
cher_c4<-faces(cluster4[5:12],main = "Cluster 4",labels= cluster4$label,cex =
0.9,ncol.plot = 1,nrow.plot = 3,face.type = 0)
cher_c5<-faces(cluster5[5:12],main = "Cluster 5",labels= cluster5$label,cex =
0.9,ncol.plot = 1,nrow.plot = 2,face.type = 0)
cher_c6<-faces(cluster6[5:12],main = "Cluster 6",labels= cluster6$label,cex =
0.9,ncol.plot = 1,nrow.plot = 3,face.type = 0)
cher_c7<-faces(cluster7[5:12],main = "Cluster 7",labels= cluster7$label,cex =
0.9,ncol.plot = 1,nrow.plot = 2,face.type = 0)
```

Se verificó que la asignación de atributos faciales en R para cada variable fuera la misma que la descrita en la *Tabla 3*. El gráfico de salida se muestra en la *Figura 2*.




Figura 2. Caras de Chernoff agrupadas por ubicación geográfica.

b) Datos de resfriados

En este ejemplo se resalta la influencia de los datos atípicos sobre los atributos faciales graficados. En la *Tabla 4* se muestran los datos semanales de resfriados que representan la frecuencia de las consultas de búsqueda en internet de Google que contiene la palabra gripe. En teoría, la frecuencia de las búsquedas varía de 0 a 100, y debido a que una perspectiva de salud pública encuentra que los valores más bajos son más deseables se definió la variable $myflu = 100 - flu$.

Tabla 4. Datos de resfriados, 2004.

t	date	flu	myflu
1	4-Nov	19.38	80.62
2	11-Nov	20.99	79.01
3	18-Nov	15.71	84.29
4	25-Nov	18.8	81.2
5	2-Dec	21.42	78.58
6	9-Dec	17.73	82.27
7	16-Dec	12.53	87.47
8	23-Dec	97.17	2.83

En comparación con la tabla presentada por Raciborski (2009), se modificó la estructura de la tabla para su importación en R. El script para graficar las caras de Chernoff sin datos atípicos y con datos atípicos fue el siguiente:

```
#Flu data
flu_datos<-read.csv("flu_data.csv",header = TRUE)
flu_datos

flu1<-flu_datos[1:7,]
flu1

#Chernoff faces sin considerar datos atipicos
flu_cher1<-faces(flu1[3:4],main = "Chernoff faces without atipics",cex=0.9)

flu2<-flu_datos[2:8,]
flu2

#Chernoff faces considerando datos atipicos
flu_cher2<-faces(flu2[3:4],main = "Chernoff faces with atipics",cex=0.9)
```

En la *Figura 3* se muestran las caras de Chernoff sin datos atípicos que no consideran los teóricos extremos representados por $t=8$, todos los valores son relativamente altos comparados con el valor más bajo cercano a cero. Cuando el valor t_8 es agregado, las características de las caras de Chernoff también se modifican notablemente (*Figura 4*).

Chernoff faces without atipics




Figura 3. Periodo de tiempo t1 - t7 sin considerar valor extremo.

Chernoff faces with atipics




Figura 4. Periodo de tiempo t2 - t8 considerando valor extremo.

Referencias

- Johnson, R. A., D. W. Wichern. 2007. Applied Multivariate Statistical Analysis. 6th ed. Upper Saddle River, NJ: Prentice Hall.
- Raciborsky, R. (2009). Graphical representation of multivariate data using Chernoff faces. The Stata Journal 9 (3), 374-387.
- Wolf, H. P. (2019). Package “aplpack”. Another Plot Package: 'Bagplots', 'Iconplots', 'Summaryplots', Slider Functions and Others. Disponible en <https://cran.r-project.org/web/packages/aplpack/aplpack.pdf>