

CASO 1

Este conjunto de datos (del repositorio de conjuntos de datos de aprendizaje automático de la UCI) contiene mediciones de imágenes satelitales en las proximidades de varias ubicaciones en una región agrícola. Cada observación tiene valores de intensidad (en el rango de 0 a 255) para cuatro bandas espectrales en cada píxel en una matriz de 3x3. A partir de observaciones terrestres, también se determinó el tipo real de cobertura vegetal en la ubicación del píxel central. Se ha seleccionado un subconjunto de 2512 observaciones en las que la cobertura del suelo era suelo rojo (codificado como clase 1), cultivo de algodón (codificado como clase 2) o suelo gris (codificado como clase 3). También se agregó una línea de encabezado con nombres para las 37 variables. La última variable es "clase", de 1 a

3. Las primeras 36 variables son las mediciones de la imagen, con nombres de la forma X_n , donde X es A, B, C, D, E, F, G, H o I, para los nueve píxeles (E es el píxel central) y n es 1, 2, 3 o 4.

- a) Realizar un análisis descriptivo y determinar la clase del píxel central a partir de las mediciones en las ubicaciones de nueve píxeles.
- b) Algunos métodos para la clasificación se basan en que las distribuciones dentro de cada clase sean multivariadas normales y con matrices de varianza covarianza homogénea, por lo que debe verificar si esto es cierto.
- c) También debe usar diagramas de dispersión con la clase identificada por color para juzgar cuán prometedora es la idea de clasificar el píxel central en función de estas medidas. ¿Parece haber mucha o poca superposición de clases en diagramas de dispersión que involucran dos variables?
- d) También debe considerar reducir la dimensionalidad de los datos es decir ejecute un PCA y en una gráfica biplot indique identifique los 3 grupos.
- e) Utilice el MANOVA para determinar si hay diferencia entre grupos.
- f) Usar métodos de Machine Learning (LDA, Random Forest, SVM y Redes Neuronales). para encontrar el mejor modelo de clasificación suponiendo que este modelo lo queremos extrapolar para predecir áreas de acuerdo a las clases en una región. Indique que método le resulta más adecuado.

1. *Análisis exploratorio de los datos espectrales*

Para cada banda, se cuenta con una cuadrícula de celdas o píxeles que representan datos de reflectancia para cada clase de cobertura de suelo, las bandas tienen dimensiones de 9 x 2512 píxeles. Como primer paso, el conjunto inicial de datos fue ordenado con la función *arrange* del paquete *dplyr* en orden de menor a mayor de acuerdo la clase de cobertura de suelo. Una vez ordenados los datos, la nueva base de datos generada fue agrupada por número de bandas ($A_1 \dots I_1; A_2 \dots I_2; A_3 \dots I_3; A_4 \dots I_4$). Se obtuvo la estadística de resumen tradicional para cada clase de cobertura del suelo (Tabla 1). La banda 2 y 3 presentan mayores desviaciones

estándar. Con la exploración de los diagramas de caja para cada clase y banda (Figura 1, Figura 2, Figura 3, y Figura 4) se observan variaciones importantes entre clases de cobertura entre las bandas 1 y 2 con las bandas 3 y 4.

Tabla 1. Análisis descriptivo de los tipos de cobertura de suelo por banda espectral.

	Clase 1 (Suelo rojo)				Clase 2 (Cultivo de algodón)				Clase 3 (Suelo gris)			
	n=1072				n=479				n=961			
Banda 1												
	Min	Media	Max	SD	Min	Media	Max	SD	Min	Media	Max	SD
A1	46.00	63.31	97.00	8.48	40.00	50.41	89.00	9.77	56.00	86.94	104.00	6.36
B1	46.00	63.03	97.00	8.09	40.00	49.72	88.00	8.79	56.00	86.97	102.00	6.15
C1	46.00	62.73	97.00	7.86	40.00	49.76	90.00	9.30	48.00	86.43	104.00	6.81
D1	46.00	63.00	97.00	8.34	40.00	50.02	92.00	9.63	53.00	87.42	102.00	5.73
E1	46.00	62.83	97.00	8.02	40.00	48.84	78.00	7.57	70.00	87.48	104.00	5.03
F1	46.00	62.63	92.00	7.57	40.00	48.93	88.00	8.03	56.00	86.86	104.00	5.98
G1	43.00	62.56	97.00	8.06	40.00	50.87	97.00	1.80	44.00	86.87	104.00	7.08
H1	46.00	62.52	92.00	7.82	39.00	49.88	89.00	9.20	49.00	86.87	104.00	6.11
I1	46.00	62.39	92.00	7.55	40.00	49.48	82.00	8.51	55.00	86.22	104.00	6.72
Banda 2												
A2	61.00	95.53	121.00	14.55	27.00	43.04	106.00	17.76	56.00	104.3	137.00	9.20
B2	43.00	95.20	121.00	14.16	27.00	41.88	107.00	16.93	58.00	104.6	137.00	8.95
C2	31.00	94.58	121.00	15.10	27.00	42.28	111.00	18.15	34.00	103.8	130.00	10.16
D2	61.00	95.30	121.00	14.54	27.00	41.63	106.00	16.91	56.00	105.2	131.00	8.24
E2	61.00	95.29	121.00	14.54	27.00	39.91	88.00	13.48	83.00	105.5	130.00	6.86
F2	54.00	94.88	121.00	14.66	27.00	40.32	103.00	15.04	57.00	104.7	130.00	8.26
G2	34.00	94.52	121.00	14.72	27.00	43.52	115.00	19.64	34.00	104.6	131.00	10.47
H2	48.00	94.73	121.00	14.75	27.00	41.47	102.00	16.45	40.00	104.9	128.00	8.47
I2	40.00	94.66	120.00	14.64	27.00	41.07	100.00	15.51	57.00	104.1	130.00	8.87
Banda 3												
A3	76.00	108.1	135.00	12.63	70.00	112.5	140.00	14.18	71.00	109.7	139.00	8.46
B3	76.00	107.9	131.00	12.51	70.00	112.9	145.00	13.76	75.00	109.8	139.00	8.33
C3	74.00	107.5	135.00	12.55	68.00	113.12	145.00	13.98	64.00	109.4	136.00	8.90
D3	76.00	108.1	135.00	12.72	70.00	113.6	145.00	12.70	79.00	110.6	139.00	7.58
E3	74.00	108.1	135.00	12.63	82.00	113.9	139.00	12.64	85.00	110.6	139.00	7.23
F3	74.00	107.8	135.00	12.64	74.00	113.5	140.00	13.55	63.00	109.8	136.00	8.34
G3	74.00	107.6	133.00	12.54	75.00	113.1	140.00	13.64	74.00	110.5	139.00	8.31
H3	74.00	107.7	133.00	12.65	67.00	113.2	145.00	13.99	76.00	110.0	139.00	8.17
I3	76.00	107.7	131.00	12.54	70.00	112.5	145.00	14.59	63.00	109.2	136.00	9.02
Banda 4												
A4	65.00	88.50	107.00	8.98	57.00	115.3	154.00	22.34	58.00	86.83	109.00	6.61
B4	65.00	88.48	122.00	8.98	57.00	116.1	157.00	21.58	58.00	86.89	109.00	6.63
C4	65.00	88.25	128.00	9.32	53.00	116.1	157.00	21.87	34.00	86.60	137.00	7.74
D4	65.00	88.52	104.00	8.93	64.00	117.6	151.00	19.94	63.00	87.53	109.00	6.03
E4	65.00	88.60	104.00	8.82	67.00	118.3	157.00	19.29	59.00	87.46	109.00	6.04
F4	65.00	88.34	113.00	8.90	55.00	117.4	154.00	21.07	34.00	87.00	109.00	7.34
G4	65.00	88.23	125.00	8.95	54.00	116.2	154.00	22.17	54.00	87.66	125.00	7.17
H4	65.00	88.34	107.00	8.91	51.00	116.9	157.00	22.02	54.00	87.20	114.00	6.96
I4	65.00	88.39	122.00	8.91	53.00	116.0	157.00	23.17	34.00	86.52	109.00	7.87




Figura 1. Diagramas de cajas y bigotes por clase de cobertura en la banda 1.




Figura 2. Diagramas de cajas y bigotes por clase de cobertura en la banda 2.




Figura 3. Diagramas de cajas y bigotes por clase de cobertura en la banda 3.




Figura 4. Diagramas de cajas y bigotes por clase de cobertura en la banda 4.




Figura 5. Gráfico de dispersión, histogramas y correlación entre las variables de la banda 1.




Figura 6. Gráfico de dispersión, histogramas y correlación entre las variables de la banda 2.




Figura 7. Gráfico de dispersión, histogramas y correlación entre las variables de la banda 3.




Figura 8. Gráfico de dispersión, histogramas y correlación entre las variables de la banda 4.

Los gráficos de dispersión, histogramas y correlaciones (Figura 5, Figura 6, Figura 7 y Figura 8), obtenidos con la función *pairs.panels* de la librería *psych* para cada una de las bandas muestran que las variables de cada banda presentan correlaciones altas, por lo que es prometedor utilizar métodos que aprovechan este tipo de relaciones lineales para la clasificación. Posiblemente, las bandas 1 y 2 no presenten normalidad en sus variables.

Por otra parte, los diagramas de Andrews tipo “cart” (Figura 9) y “polar” (Figura 10) permiten apreciar de forma más clara los tipos de cobertura de suelo en función de las variables espectrales de cada banda. Se observa que la clase 1 es mucho más fácil de detectar en las bandas 1 y 2, mientras que la clase 3 se detecta de forma más rápida mediante la banda 4.




Figura 9. Gráficas de Andrews tipo "cart" para cada banda espectral.




Figura 10. Gráficas de Andrews tipo "polar" para cada banda espectral.

2. Normalidad multivariada

El supuesto de normalidad multivariada fue estimado a partir de la agrupación de todas las variables de las cuatro bandas en subconjuntos basados en la clase de cobertura de suelo. El cumplimiento del supuesto se realizó utilizando las pruebas de Mardia, Royston, Henze-Zirkler y Energy, proporcionados por el paquete *MVN*. En este caso, en ninguna de las clases 1, 2 o 3 obtuvo, bajo ningún método, una normalidad multivariada al considerar el conjunto

de datos con multibandas. La misma situación ocurrió al considerar cada clase de cobertura dentro de cada una de las bandas 1, 2, 3 y 4 bajo la prueba de Mardia, en ningún caso se cumple el supuesto de normalidad multivariada. Es común esperar este tipo de comportamiento debido a la naturaleza de la información espectral evaluada.

3. Reducción de dimensiones

Se realizó la prueba de Bartlett para verificar si es posible la reducción de dimensiones por clase de cobertura, los valores de p fueron menores a 0.05, por lo cual, es adecuado realizar una reducción de dimensiones.

El análisis de componentes principales indica que la varianza puede ser explicada en un 91.45% si se consideran 4 componentes principales (Tabla 2), precisamente el número de bandas espectrales que contienen la información (Figura 11).

Tabla 2. Importancia de los componentes principales.

PC	Desviación estándar	% Varianza	% Varianza acumulada	PC	Desviación estándar	% Varianza	% Varianza acumulada
1	91.63	67.46	67.46	19	3.18	0.08	99.21
2	44.88	16.19	83.65	20	3.08	0.07	99.29
3	24.85	4.96	88.61	21	3.04	0.07	99.36
4	18.80	2.84	91.45	22	2.94	0.06	99.43
5	16.13	2.09	93.54	23	2.77	0.06	99.50
6	14.16	1.61	95.15	24	2.58	0.05	99.55
7	13.46	1.45	96.61	25	2.50	0.05	99.60
8	8.23	0.54	97.15	26	2.47	0.04	99.65
9	7.46	0.44	97.60	27	2.41	0.04	99.70
10	6.41	0.33	97.93	28	2.32	0.04	99.74
11	5.63	0.25	98.19	29	2.30	0.04	99.78
12	4.86	0.19	98.38	30	2.19	0.03	99.82
13	4.41	0.15	98.53	31	2.15	0.03	99.86
14	4.22	0.14	98.68	32	2.09	0.03	99.89
15	4.10	0.13	98.81	33	1.93	0.03	99.93
16	3.85	0.12	98.94	34	1.79	0.02	99.95
17	3.62	0.10	99.04	35	1.72	0.02	99.97
18	3.42	0.09	99.13	36	1.67	0.02	100.0




Figura 11. Gráfico biplot de PCA con dos componentes principales.

4. Diferencias entre grupos (MANOVA)

El análisis de diferencias entre grupos mediante MANOVA indica que hay diferencias estadísticamente significativas entre los tres diferentes tipos de cobertura de suelo, sin embargo, se debe de tener cuidado con el uso de estos valores pues uno de los supuestos del análisis no se cumple.

Tabla 3. Análisis MANOVA.

	df	Pillai	F aprox	# Df	den DF	Pr (>F)
Clases cobertura	2	1.7747	541.63	72	49.50	2.2e-16***
Residuales	2509					

5. Métodos de aprendizaje automático

Se generaron cuatro métodos de aprendizaje automático (LDA, Random Forest, SVM y Redes Neuronales). para encontrar el mejor modelo de clasificación y predicción. Los datos fueron divididos en entrenamiento (80% del conjunto total) y validación (20%).

Discriminación canónica

La función canónica *candisc* realiza un análisis discriminante canónico generalizado para un término en un modelo lineal multivariante, calculando puntuaciones y vectores canónicos. Los resultados indican que las clases 1 y 2 son las que presentan mayor significancia en la predicción de las clases por variable. Sin embargo, debe tenerse en cuenta que el supuesto de normalidad multivariada no se cumple (Tabla 4)

Tabla 4. Ajuste del modelo de discriminación canónica.

	CanRsq	Eigenvalue	Difference	Percent	Cumulative
1	0.89607	8.6218	1.3803	54.351	54.351
2	0.87866	7.2415	1.3803	45.649	100
	LR test stat	Aprox F	num DF	denDF	Pr(>F)
1	0.012611	543.24	72	4948	> 2.20E-16***
2	0.121337	512.08	35	2475	> 2.20E-16***

Análisis discriminante lineal

El Análisis Discriminante Lineal (LDA) es un método de clasificación supervisado de variables cualitativas en el que dos o más grupos son conocidos a priori y las observaciones se clasifican en alguno de esos grupos en función de sus características. Es una alternativa a la regresión logística cuando la variable cualitativa tiene más de dos niveles. Para que un análisis discriminante sea valido se deben cumplir dos condiciones: a) la varianza del predictor es igual en todas las clases de la variable y b) cada predictor que forma parte del modelo se distribuye en forma normal en cada una de las clases de la variable de respuesta. En este caso, se cuenta con un conjunto de predictores por lo que las observaciones deben seguir una normalidad multivariada, dado que no se cumplen estos supuestos, el modelo LDA pierde precisión, sin embargo, aun así, alcanza una clasificación aceptable con una precisión del 97.21% (Tabla 5 y Tabla 6).

Tabla 5. Estadísticos por clase obtenidos en LDA

	Clase 1	Clase 2	Clase 3
Sensitivity	0.972	0.9263	0.9948
Specificity	0.9895	1.0000	0.9644
Pos Pred Value	0.9858	1.0000	0.9455
Neg Pred Value	0.9793	0.9831	0.9967
Prevalence	0.4271	0.1896	0.3832
Detection Rate	0.4152	0.1756	0.3812
Detection Prevalence	0.4212	0.1756	0.4032
Balanced Accuracy	0.9808	0.9632	0.9796

Tabla 6. Matriz de confusión obtenido por LDA.

		Reference		
		1	2	3
Prediction	1	208	2	1
	2	0	88	0
	3	6	5	191

Vectorial Support Machine

En este caso, se utilizó la librería *e1071* y la función *svm*. La precisión obtenida fue alta, ligeramente superior a LDA (99.07%) (Tabla 7 y Tabla 8).

Tabla 7. Estadísticos por clase obtenidos en SVM

	Clase 1	Clase 2	Clase 3
Sensitivity	0.9813	0.9895	1
Specificity	0.9965	0.9975	0.9903
Pos Pred Value	0.9953	0.9895	0.9846
Neg Pred Value	0.9862	0.9975	1
Prevalence	0.4271	0.1896	0.3832
Detection Rate	0.4192	0.1876	0.3832
Detection Prevalence	0.4212	0.1896	0.3892
Balanced Accuracy	0.9889	0.9935	0.9951

Tabla 8. Matriz de confusión obtenido por SVM.

		Reference		
		1	2	3
Prediction	1	210	2	1
	2	0	94	0
	3	6	5	192

Random Forest

Los modelos Random Forest están formados por un conjunto de árboles de decisión individuales, cada uno es entrenado con una muestra ligeramente distinta de los datos de entrenamiento generada mediante bootstrapping. La predicción de una nueva observación se obtiene agregando las predicciones de todos los árboles individuales que forman el modelo. En este caso, se probaron manualmente diferentes valores de *mtry* y se observó una estabilización del error OBB utilizando 1000 árboles de decisión. Se obtuvo una precisión del 98.2%, la cual fue ligeramente inferior que SVM (Tabla 9 y Tabla 10).




Figura 12. Importancia de las variables obtenidas por RF.

La muestra que la variable más importante para clasificar la clase de cobertura es precisamente el pixel central de la matriz de 3 x 3 de cada banda.

Tabla 9. Estadísticos por clase obtenidos en RF

	Clase 1	Clase 2	Clase 3
Sensitivity	0.9766	0.9895	0.9844
Specificity	0.9895	0.9951	0.9871
Pos Pred Value	0.9858	0.9792	0.9793
Neg Pred Value	0.9827	0.9975	0.9903
Prevalence	0.4271	0.1896	0.3832
Detection Rate	0.4172	0.1876	0.3772
Detection Prevalence	0.4232	0.1916	0.3852
Balanced Accuracy	0.9831	0.9923	0.9857

Tabla 10. Matriz de confusión obtenido por RF.

		Reference		
		1	2	3
Prediction	1	209	2	1
	2	0	94	0
	3	6	5	189

Redes neuronales

Las Redes Neuronales Artificiales son modelos computacionales inspirados en las neuronas biológicas, y que están conformadas por un conjunto de unidades de cómputo básico (neuronas) las cuales están conectadas entre ellas de múltiples maneras. Estas conexiones están definidas por pesos que determinan la fuerza o importancia de dichas conexiones, y durante el proceso de aprendizaje o entrenamiento de la red, dichos pesos se ajustan para producir la salida adecuada según la entrada que se aplique a la red. Para este método, se obtuvo una precisión similar a RF, con un valor de 98.6% (Tabla 11 y Tabla 12)

Tabla 11. Estadísticos por clase obtenidos en RN

	Clase 1	Clase 2	Clase 3
Sensitivity	0.986	0.9895	0.9844
Specificity	0.9895	1.0000	0.9871
Pos Pred Value	0.986	1.0000	0.9793
Neg Pred Value	0.9895	0.9975	0.9903
Prevalence	0.4271	0.1896	0.3832
Detection Rate	0.4212	0.1876	0.3772
Detection Prevalence	0.4271	0.1876	0.3852
Balanced Accuracy	0.9878	0.9947	0.9857

Tabla 12. Matriz de confusión obtenido por RN.

		Reference		
		1	2	3
Prediction	1	211	2	1
	2	0	94	0
	3	6	5	189

6. Código en R

Z

```
#Examen
#Problema 1.
#Presenta: Zaira Rosario Pérez Vázquez

#Conjunto de datos
rm(list=ls())
setwd("C:/Users/zaira/Documents/01 - Doctorado PCF/Otoño 2020/Analisis
multivariado/Examen/Rscripts")
datos<-read.csv("datos problema1.csv",header=TRUE)
view(datos)
options(max.print = 100000)

#Librerias
library(dplyr)
library(psych)
library(MVN)
library(mvShapiroTest)
library(pracma)
library(andrews)
library(FactoMiner)
library(psych)
library(factoextra)
library(multiDimBio)
library(candisc)
library(randomForest)
library(caret)
library(BiocManager)
library(MASS)
library(e1071)
library(nnet)
library(NeuralNetTools)
library(rpart)

###1. Analisis exploratorio de los datos espectrales

##Ordenar los datos por clase de suelo
datos_clases<-arrange(datos,datos$class)
view(datos_clases)

##Clasificación en bandas
banda1<-
data.frame(datos_clases$A1,datos_clases$B1,datos_clases$C1,datos_clases
$D1,datos_clases$E1,datos_clases$F1,datos_clases$G1,datos_clases$H1,dat
os_clases$I1,datos_clases$class)
banda2<-
data.frame(datos_clases$A2,datos_clases$B2,datos_clases$C2,datos_clases
$D2,datos_clases$E2,datos_clases$F2,datos_clases$G2,datos_clases$H2,dat
os_clases$I2,datos_clases$class)
banda3<-
data.frame(datos_clases$A3,datos_clases$B3,datos_clases$C3,datos_clases
$D3,datos_clases$E3,datos_clases$F3,datos_clases$G3,datos_clases$H3,dat
os_clases$I3,datos_clases$class)
banda4<-
data.frame(datos_clases$A4,datos_clases$B4,datos_clases$C4,datos_clases
$D4,datos_clases$E4,datos_clases$F4,datos_clases$G4,datos_clases$H4,dat
os_clases$I4,datos_clases$class)
view(banda1)
view(banda2)
view(banda3)
```

```
view(banda4)
banda1$datos_clases.class<-as.factor(banda1$datos_clases.class)
banda2$datos_clases.class<-as.factor(banda2$datos_clases.class)
banda3$datos_clases.class<-as.factor(banda3$datos_clases.class)
banda4$datos_clases.class<-as.factor(banda4$datos_clases.class)
names(banda1)<-c("A1","B1","C1","D1","E1","F1","G1","H1","I1","Clase")
names(banda2)<-c("A2","B2","C2","D2","E2","F2","G2","H2","I2","Clase")
names(banda3)<-c("A3","B3","C3","D3","E3","F3","G3","H3","I3","Clase")
names(banda4)<-c("A4","B4","C4","D4","E4","F4","G4","H4","I4","Clase")

##Análisis exploratorio por clase de suelo

#Banda 1
summary(banda1[1:1072,])      #Clase 1
summary(banda1[1073:1551,])  #Clase 2
summary(banda1[1552:2512,])  #Clase 3
sd(banda1[1:1072,]$A1)
sd(banda1[1:1072,]$B1)
sd(banda1[1:1072,]$C1)
sd(banda1[1:1072,]$D1)
sd(banda1[1:1072,]$E1)
sd(banda1[1:1072,]$F1)
sd(banda1[1:1072,]$G1)
sd(banda1[1:1072,]$H1)
sd(banda1[1:1072,]$I1)
sd(banda1[1073:1551,]$A1)
sd(banda1[1073:1551,]$B1)
sd(banda1[1073:1551,]$C1)
sd(banda1[1073:1551,]$D1)
sd(banda1[1073:1551,]$E1)
sd(banda1[1073:1551,]$F1)
sd(banda1[1073:1551,]$G1)
sd(banda1[1073:1551,]$H1)
sd(banda1[1073:1551,]$I1)
sd(banda1[1552:2512,]$A1)
sd(banda1[1552:2512,]$B1)
sd(banda1[1552:2512,]$C1)
sd(banda1[1552:2512,]$D1)
sd(banda1[1552:2512,]$E1)
sd(banda1[1552:2512,]$F1)
sd(banda1[1552:2512,]$G1)
sd(banda1[1552:2512,]$H1)
sd(banda1[1552:2512,]$I1)
#Banda 2
summary(banda2[1:1072,])      #Clase 1
summary(banda2[1073:1551,])  #Clase 2
summary(banda2[1552:2512,])  #Clase 3
sd(banda2[1:1072,]$A2)
sd(banda2[1:1072,]$B2)
sd(banda2[1:1072,]$C2)
sd(banda2[1:1072,]$D2)
sd(banda2[1:1072,]$E2)
sd(banda2[1:1072,]$F2)
sd(banda2[1:1072,]$G2)
sd(banda2[1:1072,]$H2)
sd(banda2[1:1072,]$I2)
sd(banda2[1073:1551,]$A2)
sd(banda2[1073:1551,]$B2)
sd(banda2[1073:1551,]$C2)
sd(banda2[1073:1551,]$D2)
sd(banda2[1073:1551,]$E2)
sd(banda2[1073:1551,]$F2)
sd(banda2[1073:1551,]$G2)
sd(banda2[1073:1551,]$H2)
sd(banda2[1073:1551,]$I2)
sd(banda2[1552:2512,]$A2)
```



```

sd(banda2[1552:2512,]$B2)
sd(banda2[1552:2512,]$C2)
sd(banda2[1552:2512,]$D2)
sd(banda2[1552:2512,]$E2)
sd(banda2[1552:2512,]$F2)
sd(banda2[1552:2512,]$G2)
sd(banda2[1552:2512,]$H2)
sd(banda2[1552:2512,]$I2)
#Banda 3
summary(banda3[1:1072,])      #Clase 1
summary(banda3[1073:1551,])  #Clase 2
summary(banda3[1552:2512,])  #Clase 3
sd(banda3[1:1072,]$A3)
sd(banda3[1:1072,]$B3)
sd(banda3[1:1072,]$C3)
sd(banda3[1:1072,]$D3)
sd(banda3[1:1072,]$E3)
sd(banda3[1:1072,]$F3)
sd(banda3[1:1072,]$G3)
sd(banda3[1:1072,]$H3)
sd(banda3[1:1072,]$I3)
sd(banda3[1073:1551,]$A3)
sd(banda3[1073:1551,]$B3)
sd(banda3[1073:1551,]$C3)
sd(banda3[1073:1551,]$D3)
sd(banda3[1073:1551,]$E3)
sd(banda3[1073:1551,]$F3)
sd(banda3[1073:1551,]$G3)
sd(banda3[1073:1551,]$H3)
sd(banda3[1073:1551,]$I3)
sd(banda3[1552:2512,]$A3)
sd(banda3[1552:2512,]$B3)
sd(banda3[1552:2512,]$C3)
sd(banda3[1552:2512,]$D3)
sd(banda3[1552:2512,]$E3)
sd(banda3[1552:2512,]$F3)
sd(banda3[1552:2512,]$G3)
sd(banda3[1552:2512,]$H3)
sd(banda3[1552:2512,]$I3)
#Banda 4
summary(banda4[1:1072,])      #Clase 1
summary(banda4[1073:1551,])  #Clase 2
summary(banda4[1552:2512,])  #Clase 3
sd(banda4[1:1072,]$A4)
sd(banda4[1:1072,]$B4)
sd(banda4[1:1072,]$C4)
sd(banda4[1:1072,]$D4)
sd(banda4[1:1072,]$E4)
sd(banda4[1:1072,]$F4)
sd(banda4[1:1072,]$G4)
sd(banda4[1:1072,]$H4)
sd(banda4[1:1072,]$I4)
sd(banda4[1073:1551,]$A4)
sd(banda4[1073:1551,]$B4)
sd(banda4[1073:1551,]$C4)
sd(banda4[1073:1551,]$D4)
sd(banda4[1073:1551,]$E4)
sd(banda4[1073:1551,]$F4)
sd(banda4[1073:1551,]$G4)
sd(banda4[1073:1551,]$H4)
sd(banda4[1073:1551,]$I4)
sd(banda4[1552:2512,]$A4)
sd(banda4[1552:2512,]$B4)
sd(banda4[1552:2512,]$C4)
sd(banda4[1552:2512,]$D4)
sd(banda4[1552:2512,]$E4)

```

```
sd(banda4[1552:2512,]$F4)
sd(banda4[1552:2512,]$G4)
sd(banda4[1552:2512,]$H4)
sd(banda4[1552:2512,]$I4)

##Diagramas de boxplot

#Banda 1
png("P1_1.BoxplotB1.png",width = 710,height = 560)
par(mfrow=c(3,3),cex=0.9,mar=c(1.8,1.9,1.9,1.6))
boxplot(banda1$A1~banda1$Clase,main="A1")
boxplot(banda1$B1~banda1$Clase,main="B1")
boxplot(banda1$C1~banda1$Clase,main="C1")
boxplot(banda1$D1~banda1$Clase,main="D1")
boxplot(banda1$E1~banda1$Clase,main="E1")
boxplot(banda1$F1~banda1$Clase,main="F1")
boxplot(banda1$G1~banda1$Clase,main="G1")
boxplot(banda1$H1~banda1$Clase,main="H1")
boxplot(banda1$I1~banda1$Clase,main="I1")
dev.off()

#Banda2
png("P1_2.BoxplotB2.png",width = 710,height = 560)
par(mfrow=c(3,3),cex=0.9,mar=c(1.8,1.9,1.9,1.6))
boxplot(banda2$A2~banda2$Clase,main="A2")
boxplot(banda2$B2~banda2$Clase,main="B2")
boxplot(banda2$C2~banda2$Clase,main="C2")
boxplot(banda2$D2~banda2$Clase,main="D2")
boxplot(banda2$E2~banda2$Clase,main="E2")
boxplot(banda2$F2~banda2$Clase,main="F2")
boxplot(banda2$G2~banda2$Clase,main="G2")
boxplot(banda2$H2~banda2$Clase,main="H2")
boxplot(banda2$I2~banda2$Clase,main="I2")
dev.off()

#Banda3
png("P1_3.BoxplotB3.png",width = 710,height = 560)
par(mfrow=c(3,3),cex=0.9,mar=c(1.8,1.9,1.9,1.6))
boxplot(banda3$A3~banda3$Clase,main="A3")
boxplot(banda3$B3~banda3$Clase,main="B3")
boxplot(banda3$C3~banda3$Clase,main="C3")
boxplot(banda3$D3~banda3$Clase,main="D3")
boxplot(banda3$E3~banda3$Clase,main="E3")
boxplot(banda3$F3~banda3$Clase,main="F3")
boxplot(banda3$G3~banda3$Clase,main="G3")
boxplot(banda3$H3~banda3$Clase,main="H3")
boxplot(banda3$I3~banda3$Clase,main="I3")
dev.off()

#Banda 4
png("P1_4.BoxplotB4.png",width = 710,height = 560)
par(mfrow=c(3,3),cex=0.9,mar=c(1.8,1.9,1.9,1.6))
boxplot(banda4$A4~banda4$Clase,main="A4")
boxplot(banda4$B4~banda4$Clase,main="B4")
boxplot(banda4$C4~banda4$Clase,main="C4")
boxplot(banda4$D4~banda4$Clase,main="D4")
boxplot(banda4$E4~banda4$Clase,main="E4")
boxplot(banda4$F4~banda4$Clase,main="F4")
boxplot(banda4$G4~banda4$Clase,main="G4")
boxplot(banda4$H4~banda4$Clase,main="H4")
boxplot(banda4$I4~banda4$Clase,main="I4")
dev.off()

##Diagramas de dispersión, histogramas y correlacion.
#Banda1
png("P1_5.DispersionB1.png",width = 710,height = 560)
```

```
pairs.panels(banda1,pch = 0.1)
dev.off()
#Banda2
png("P1_6.DispersionB2.png",width = 710,height = 560)
pairs.panels(banda2,pch = 0.1)
dev.off()
#Banda3
png("P1_7.DispersionB3.png",width = 710,height = 560)
pairs.panels(banda3,pch = 0.1)
dev.off()
#Banda4
png("P1_8.DispersionB4.png",width = 710,height = 560)
pairs.panels(banda4,pch = 0.1)
dev.off()
pairs

#Gráfico de Andrews tipo pol
?andrewsplot()
#Banda1
andrewsplot(as.matrix(banda1[1:9]),banda1[,10], style = "pol")
title(main=NULL,sub="Banda1")
#Banda2
andrewsplot(as.matrix(banda2[1:9]),banda2[,10], style = "pol")
title(main=NULL,sub="Banda2")
#Banda3
andrewsplot(as.matrix(banda3[1:9]),banda3[,10], style = "pol")
title(main=NULL,sub="Banda3")
#Banda4
andrewsplot(as.matrix(banda4[1:9]),banda4[,10], style = "pol")
title(main=NULL,sub="Banda4")

#Gráfico de Andrews tipo cart
#Banda1
andrewsplot(as.matrix(banda1[1:9]),banda1[,10], style = "cart")
title(main=NULL,sub="Banda1")
#Banda2
andrewsplot(as.matrix(banda2[1:9]),banda2[,10], style = "cart")
title(main=NULL,sub="Banda2")
#Banda3
andrewsplot(as.matrix(banda3[1:9]),banda3[,10], style = "cart")
title(main=NULL,sub="Banda3")
#Banda4
andrewsplot(as.matrix(banda4[1:9]),banda4[,10], style = "cart")
title(main=NULL,sub="Banda4")

###2. Normalidad multivariada

#Normalidad multivariada por clase de cobertura en las 4 bandas evaluadas
clase1<-datos_clases[1:1072,]
clase2<-datos_clases[1073:1551,]
clase3<-datos_clases[1552:2512,]
(view(clase1))

#Clase1
Norm1<-mvn(data = clase1[,1:36],mvnTest = "mardia")
Norm1$multivariateNormality
Norm1<-mvn(data = clase1[,1:36],mvnTest = "hz")
Norm1$multivariateNormality
Norm1<-mvn(data = clase1[,1:36],mvnTest = "royston")
Norm1$multivariateNormality
Norm1<-mvn(data = clase1[,1:36],mvnTest = "dh")
Norm1$multivariateNormality
Norm1<-mvn(data = clase1[,1:36],mvnTest = "energy")
Norm1$multivariateNormality
```

```
#Clase2
Norm2<-mvn(data = clase2[,1:36],mvnTest = "mardia")
Norm2$multivariateNormality
Norm2<-mvn(data = clase2[,1:36],mvnTest = "hz")
Norm2$multivariateNormality
Norm2<-mvn(data = clase2[,1:36],mvnTest = "royston")
Norm2$multivariateNormality
Norm2<-mvn(data = clase2[,1:36],mvnTest = "dh")
Norm2$multivariateNormality
Norm2<-mvn(data = clase2[,1:36],mvnTest = "energy")
Norm2$multivariateNormality

#Clase3
Norm3<-mvn(data = clase3[,1:36],mvnTest = "mardia")
Norm3$multivariateNormality
Norm3<-mvn(data = clase3[,1:36],mvnTest = "hz")
Norm3$multivariateNormality
Norm3<-mvn(data = clase3[,1:36],mvnTest = "royston")
Norm3$multivariateNormality
Norm3<-mvn(data = clase3[,1:36],mvnTest = "dh")
Norm3$multivariateNormality
Norm3<-mvn(data = clase3[,1:36],mvnTest = "energy")
Norm3$multivariateNormality

#Normalidad multivariada por clase de cobertura en cada bandas evaluadas
#Banda1 - Clase 1-3
View(banda1[1:1072,1:9])
Norm_B1C1<-mvn(data = banda1[1:1072,1:9],mvnTest = "mardia")
Norm_B1C1
Norm_B1C2<-mvn(data = banda1[1073:1551,1:9],mvnTest = "mardia")
Norm_B1C2
Norm_B1C3<-mvn(data = banda1[1552:2512,1:9],mvnTest = "mardia")
Norm_B1C3

#Banda2 - Clase 1-3
View(banda2[1:1072,1:9])
Norm_B2C1<-mvn(data = banda2[1:1072,1:9],mvnTest = "mardia")
Norm_B2C1
Norm_B2C2<-mvn(data = banda2[1073:1551,1:9],mvnTest = "mardia")
Norm_B2C2
Norm_B2C3<-mvn(data = banda2[1552:2512,1:9],mvnTest = "mardia")
Norm_B2C3

#Banda3 - Clase 1-3
View(banda1[1:1072,1:9])
Norm_B3C1<-mvn(data = banda3[1:1072,1:9],mvnTest = "mardia")
Norm_B3C1
Norm_B3C2<-mvn(data = banda3[1073:1551,1:9],mvnTest = "mardia")
Norm_B3C2
Norm_B3C3<-mvn(data = banda3[1552:2512,1:9],mvnTest = "mardia")
Norm_B3C3

#Banda4 - Clase 1-3
View(banda1[1:1072,1:9])
Norm_B4C1<-mvn(data = banda4[1:1072,1:9],mvnTest = "mardia")
Norm_B4C1
Norm_B4C2<-mvn(data = banda4[1073:1551,1:9],mvnTest = "mardia")
Norm_B4C2
Norm_B4C3<-mvn(data = banda4[1552:2512,1:9],mvnTest = "mardia")
Norm_B4C3

### 3. Reducción de dimensiones por PCA

#Prueba de Bartlett (El valor de n representa el numero de observaciones
totales por clase)
bartlett.test(clase1[,1:36],n=1072)
```

```
bartlett.test(clase2[,1:36],n=479)
bartlett.test(clase3[,1:36],n=961)

view(datos_clases[,1:36])
?prcomp
PCA_multibanda<-prcomp(datos_clases[,1:36],center = TRUE,scale. = FALSE)
summary(PCA_multibanda)
biplot(PCA_multibanda,scale = 0)

#Considerando la extracción de cuatro componentes
PCA_multibanda4<-PCA(datos_clases[,1:36],scale=FALSE,ncp=4)

fviz_screplot(PCA_multibanda4,addlabels=FALSE,geom="line")
plot(PCA_multibanda4,choix = "ind",cex=0.7)
plot.PCA(PCA_multibanda4,axes=c(1,2),choix = "var",habillage =
2,cex=0.7,ellipse = TRUE)
paleta<-c("#451460","#56b893","#a9c12a")
fviz_pca_var(PCA_multibanda4,col.var =
"cos2",gradient.cols=paleta,repel=TRUE)

clases_cobertura<-as.factor(datos_clases[,37])

### 4. Diferencias entre grupos MANOVA
model<-lm(as.matrix(datos_clases[,1:36])~as.factor(clases_cobertura))

manova
Manova1<-manova(model)
summary(Manova1)

### 5. Métodos de aprendizaje automático
set.seed(100100)

#Datos de entrenamiento y validación
datos_clases$class<-as.factor(datos_clases$class)

Y_resp<-datos_clases[,37]
View(Y_resp)
X_pred <- datos_clases[,1:36]
View(X_pred)
particion<-createDataPartition(Y_resp, p=0.80, list=FALSE, times=1)
training<-datos_clases[particion,]
View(training)
validation<-datos_clases[-particion,]
View(validation)

#Discriminación canónica
DiscrimCan<-candisc(model,data = training, ndim =2)
DiscrimCan
DiscrimCan$coeffs.std
DiscrimCan$structure
plot(DiscrimCan)

#LDA
LDA1<-lda(training$class~.,data = training)
LDA1
LDA_pred <-predict(LDA1, validation)
confusionMatrix(LDA_pred$class, validation$class)

#Vectorial support
SVM1<- svm(training$class~., data=training)
summary(SVM1)
SVM1$rho
SVM_pred <- predict(SVM1, validation)
confusionMatrix(SVM_pred, validation$class)

#Decision trees
```

```
trees=rpart(training$class~., data=training)
rpart::plotcp(trees)
rpart.plot(trees)

#Random Forest
RF_1<- randomForest(training$class~., data = training, mtry=10,
ntree=1000)
RF_1
plot(RF_1)
varImpPlot(RF_1)
RF_pred <- predict(RF_1, validation)
confusionMatrix(RF_pred, validation$class)

#Redes neuronales
NN1=nnet(training$class~., data = training,size=10, decay=0.1,
maxit=1000)
NN1
NN1_pred= data.frame(predict(NN1, validation), class=predict(NN1,
validation, type="class"))
View(training$class)
plotnet(NN1)
confusionMatrix(NN1_pred$class, validation$class)
```

CASO 2

Del artículo: “Germinación y vigor de semillas de poblaciones de maíz con diferente proporción de endospermo vítreo”

Donde estudian los atributos de calidad fisiológica de semillas son componentes importantes para ampliar la caracterización del germoplasma. Se evaluaron 35 poblaciones de maíz (*Zea mays* L.) criollo con diferente tipo de endospermo, con el objetivo de establecer la relación entre el endospermo vítreo con la germinación de semillas y vigor de plántulas.

- Realice una correlación canónica entre variables de endospermo vítreo y germinación., obtenga la gráfica.
- Realice una regresión PLS para modelar el efecto de variables de endospermo vítreo y germinación.
- Realice un análisis de agrupamiento jerárquico para identificar grupos entre las poblaciones de maíz. Adjunte dendrogramas.

1. Agrupamiento de variables

Las variables fueron agrupadas atendiendo a las necesidades del estudio, por un lado, las variables relacionadas con las características estructurales de las semillas de cada población y, por otro lado, las variables relacionadas con las características fisiológicas (Tabla 13).

Tabla 13. Variables estructurales y morfológicas de maíz criollo.

Variables estructurales (Predictor)		Variables fisiológicas (Respuesta)	
Descripción	Notación	Descripción	Notación
Peso de 100 granos	$x_1: PG$	Germinación (%)	$y_1: GR$
Endospermo harinoso (g)	$x_2: EH$	Vigor (cm)	$y_2: V$
Endospermo vitreo (g)	$x_3: EV$	Plantas normales (%)	$y_3: PN$
Pericarpio (g)	$x_4: PER$	Plantas anormales (%)	$y_4: PA$
Germen (g)	$x_5: G$	Semillas muertas (%)	$y_5: SM$

2. Estadística descriptiva

Previo al análisis, se obtuvieron los estadísticos tradicionales de resumen. En este caso, los valores obtenidos son similares a los reportados por De la Cruz *et al.* (2018), a excepción de los valores de variación del endospermo vitreo, cuyos valores se encuentran entre 0.079 y 0.210 (Tabla 14).

Tabla 14, Valores máximos, mínimos y medios de las variables estructurales y fisiológicas.

Variables estructurales				Variables fisiológicas			
Variable	Mínimo	Máximo	Media	Variable	Mínimo	Máximo	Media
PG (g)	26.060	37.44	29.160	GR	28.00	100.00	92.00
EH	0.068	0.152	0.110	V	0.72	9.27	6.11
EV	0.079	0.210	0.131	PN	16.00	97.33	81.33
PER	0.016	0.031	0.023	PA	1.33	44.00	9.33
G	0.019	0.046	0.029	SM	1.33	61.33	8.00

3. Relación entre variables

Para explorar las relaciones entre cada conjunto de variables se crearon gráficas de correlación con ayuda de la librería *GGally* y la función *ggpairs* (Figura 13 y Figura 14). Se observa que la correlación lineal entre las variables estructurales es bastante baja, a diferencia de las variables fisiológicas que presentan correlaciones superiores al 80% en su mayoría.




Figura 13. Correlación entre variables estructurales.




Figura 14. Correlación entre variables fisiológicas.

4. Análisis de correlación canónica

El análisis de correlación canónica se realizó utilizando la librería *CCA* y la función *cc* y fue verificada con la función *CCorA* del paquete *vegan*. Los coeficientes de correlación obtenidos por ambos métodos se muestran en la Tabla 15. Se obtuvo una significancia a partir de la traza de Pillai de 0.65 (Tabla 15).

Tabla 15. Coeficientes de correlación canónica.

	Eje1	Eje2	Eje3	Eje4	Eje5
Correlación canónica	0.6155	0.4916	0.1538	0.0463	0.0232

Las cargas de las variables en las dimensiones canónicas se calcularon con la función *comput* de la misma librería (Tabla 16). Estas cargas son las correlaciones entre las variables y las variables canónicas. En general, el número de dimensiones canónicas es igual al número de variables en el conjunto más pequeño. Las dimensiones canónicas, también conocidas como

variables canónicas, son variables latentes que son análogas a los factores obtenidos en el análisis factorial.

Tabla 16. Cargas de las variables en las dimensiones canónicas.

	Eje1	Eje2	Eje3	Eje4	Eje5
Corr X xscores					
PG	-0.694	-0.692	0.172	-0.048	0.081
EH	-0.125	-0.594	-0.362	0.251	0.660
EV	-0.691	-0.100	0.636	-0.264	-0.190
PER	0.058	-0.674	0.035	-0.723	-0.130
G	0.064	-0.969	0.100	0.112	-0.184
Corr Y xscores					
GR	0.566	-0.073	-0.026	0.001	0.007
V	0.562	-0.043	0.024	0.016	-0.001
PN	0.514	-0.175	0.047	0.012	0.002
PA	-0.387	0.261	-0.052	-0.013	0.008
SM	-0.505	0.098	-0.024	-0.011	0.010
Corr X yscores					
PG	-0.427	-0.340	0.026	-0.002	0.001
EH	-0.076	-0.292	-0.055	0.011	0.015
EV	-0.425	-0.049	0.097	-0.012	-0.004
PER	0.035	-0.331	0.005	-0.033	-0.003
G	0.039	-0.476	0.015	0.005	-0.004
Corr Y yscores					
GR	0.919	-0.149	-0.172	0.013	0.318
V	0.914	-0.088	0.158	0.359	-0.048
PN	0.836	-0.356	0.306	0.264	0.097
PA	-0.629	0.531	-0.339	-0.288	0.350
SM	-0.821	0.201	-0.156	-0.247	-0.445

En la Figura 15 se observan las correlaciones entre cada grupo de variables y en combinación; las correlaciones entre las variables estructurales son menores con valores predominantes menores a 0.5, mientras que las variables fisiológicas están altamente correlacionadas tanto positiva como negativamente. Sin embargo, la correlación entre ambos grupos es ligera. La Figura 16 muestra que las variables con mayor relación son el GR (% de germinación), V (vigor) y PN (% de plantas normales), así como una relación entre las variables PA (% de plantas anormales) y SM (% de semillas muertas).




Figura 15. Correlaciones entre variables estructurales (X) y fisiológicas (Y) obtenida con la función "matcor".




Figura 16. Gráfica biplot de la relación entre variables estructurales y fisiológicas, obtenida con la función "cc".

Se realizó la prueba asintótica para la significancia estadística de los coeficientes de correlación canónica. Para ello, se utilizó la función *p.asym* de la librería *CCP*, esta función ejecuta pruebas asintóticas para asignar la significancia estadística de los coeficientes de

correlación canónica con aproximaciones F de lambda de Wilks como estadístico de prueba. Como se muestra en la Tabla 17, la primera prueba de las dimensiones canónicas prueba si las cinco dimensiones son significativas, sin embargo, la prueba indica lo contrario, con un nivel de significancia de 0.05, con una correlación canónica de 0.458.

Tabla 17. Prueba de significancia de correlación canónica (F de Wilks).

Dimensiones	Corr	F	df1	df2	P
1-5	0.458	0.881	25	94.372	0.628
2-5	0.738	0.522	16	80.068	0.927
3-5	0.973	0.080	9	65.861	0.999
4-5	0.997	0.018	4	56.000	0.999
5-5	0.999	0.015	1	29.000	0.901

Sin embargo, utilizando la aproximación F con la traza Pillai-Bartlett, la correlación canónica incrementa, pero la significancia se mantiene (Tabla 18). La correlación obtenida (0.6469) fue igual a la derivada con la función *CCorA*. Posiblemente la baja significancia se debe a que las variables estructurales no presentaban una correlación lineal significativa (Figura 13).

Tabla 18. Prueba de significancia de correlación canónica (Traza Pillai-Bartlett).

Dimensiones	Corr	F	df1	df2	P
1-5	0.6469	0.8620	25	145	0.656
2-5	0.2680	0.5488	16	155	0.916
3-5	0.0263	0.0971	9	165	0.999
4-5	0.0026	0.0235	4	175	0.998
5-5	0.0005	0.0199	1	185	0.887

5. Regresión PLS

El análisis de correlación canónica y la regresión PLS son técnicas conocidas para extraer características de dos conjuntos de variables multidimensionales. La diferencia fundamental entre CCA y PLS es que la primera maximiza la correlación mientras que la segunda maximiza la covarianza. La regresión PLS fue obtenida utilizando la función *pls* de la librería *pls*. El conjunto de datos fue dividido en entrenamiento (75%) y validación (25%). Las variables de respuesta y predictoras nuevamente fueron agrupadas conforme a la Tabla 13. Con la partición de datos, de los 35 registros de poblaciones, se seleccionaron aleatoriamente 27 poblaciones para el entrenamiento del modelo y 8 poblaciones para validación del mismo.

El porcentaje de varianza explicado por el modelo PLS para cada componente se muestra en la Tabla 19. Se observa que la variable PA (plantas anormales) presento el menor porcentaje

de varianza explicado, mientras que la variable multidimensional X (conjunto de variables estructurales) explicaron el 39.86% de la varianza total, por lo que se requiere considerar al menos 3 componentes en el análisis. Los coeficientes obtenidos para los primeros tres componentes obtenidos por PLS se muestran en la Tabla 20.

Tabla 19. Porcentaje de varianza explicada por el modelo PLS.

	Comp1	Comp2	Comp3	Comp4	Comp5
X	39.863	66.32	88.35	99.49	100.00
GR	24.690	36.63	38.02	38.18	39.80
V	18.670	29.56	31.58	32.89	34.44
PN	13.586	25.38	26.87	28.72	31.59
PA	5.037	17.72	18.01	19.58	22.03
SM	16.234	23.29	25.50	26.87	28.98

Tabla 20. Coeficientes obtenidos para los primeros tres componentes del modelo PLS.

		GR	V	PN	PA	SM
Comp1	PG	-6.792	-0.796	-5.897	1.729	4.168
	EH	-0.553	-0.064	-0.480	0.121	0.339
	EV	-6.858	-0.803	-5.954	1.746	4.208
	PER	0.777	0.091	0.674	-0.197	-0.477
	G	2.493	0.292	2.164	-0.634	-1.529
Comp2	PG	-9.397	-1.131	-8.928	3.243	5.684
	EH	-1.071	-0.131	-1.083	0.441	0.641
	EV	-9.348	-1.124	-8.851	3.193	5.657
	PER	4.980	0.632	5.564	-2.640	-2.922
	G	9.395	1.180	10.194	-4.646	5.546
Comp3	PG	-10.839	-1.365	-10.673	3.614	7.058
	EH	-3.199	-0.477	-3.659	0.988	2.669
	EV	-8.306	-0.955	-7.590	2.926	4.664
	PER	4.310	0.523	4.753	-2.468	-2.284
	G	10.866	1.419	11.975	-5.024	-6.948

En la Figura 17 se muestra el número de componentes al cual la raíz cuadrada el error disminuye o incrementa. Se observa que para las variables V (vigor), PN (plantas normales), son suficientes 3 componentes, sin embargo, para el resto de las variables de respuesta, RMSE presenta un comportamiento menos estable. Se observa en la Figura 18, a diferencia de CCA, que con PLS se identifica una mejor relación con las variables EH (endospermo harinoso) y V (vigor), así como de GR (germinación) con PN (planta normal).




Figura 17. Raíz cuadrada del error por variable de respuesta.




Figura 18. Gráfica biplot de la relación entre variables estructurales y fisiológicas obtenidas por PLS.

6. Agrupamiento jerárquico

La agrupación jerárquica permite agrupar puntos de datos similares a partir de cierta jerarquía. En este caso, el agrupamiento se obtuvo mediante el método de Ward el cual

minimiza la varianza total dentro del grupo. Para realizar el agrupamiento, los datos fueron previamente escalados, es decir que cada variable tendrá media 0 y desviación estándar 1. Posteriormente, se calculó la distancia euclidiana, se definieron cinco grupos con el método de Ward mediante la función *hclust* y *cutree* del paquete *stats*. El agrupamiento también se realizó por *kmeans* (Tabla 21). Mediante la librería *factoextra* se obtuvieron los dendrogramas (Figura 19, Figura 20). En conclusión, estos algoritmos son capaces entonces de encontrar las semejanzas intrínsecas de los datos y producir clases que, en efecto, reproducen lo que puede observarse de manera intuitiva.




Figura 19. Agrupamiento cluster de poblaciones de maíz.

Tabla 21. Poblaciones agrupadas jerárquicamente.

Cluster	Poblaciones
1	1, 4, 6, 5, 14, 7, 18
2	3, 2, 11, 12, 8, 10
3	16, 15, 9, 13
4	26, 20, 23, 35, 30, 29, 31, 17, 32
5	34, 22, 33, 21, 27, 19, 25, 24, 28




Figura 20. Dendrograma de poblaciones de maíz agrupadas jerárquicamente.

7. Código en R

```
#Examen
#Problema 2
#Presenta Zaira Perez
rm(list())

#Lectura de datos
setwd("C:/Users/zaira/Documents/01 - Doctorado PCF/Otoño 2020/Analisis
multivariado/Examen/Rscripts")
datos<-read.csv("datos problema2.csv")
view(datos)

#Librerias
library(ggplot2)
library(GGally)
library(CCA)
library(vegan)
library(CCP)
library(MVN)
library(PMA)
library(caret)
library(pls)
library(dplyr)
library(factoextra)

#1. Agrupamiento de variables
names(datos)<-
c("Poblacion", "PG", "EH", "EV", "PER", "G", "GR", "V", "PN", "PA", "SM")
Xmat<-datos[,2:6]
```



```
View(Xmat)
Ymat<-datos[,7:11]
View(Ymat)

#2. Descriptivo
summary(Xmat)
summary(Ymat)

#3. Relación entre variables
png("P2_1.CorrelacionXvars.png",width = 700,height = 550)
ggpairs(Xmat)
dev.off()

png("P2_2.CorrelacionYvars.png",width = 700,height = 550)
ggpairs(Ymat)
dev.off()

#4. Correlacion canonica

Corr_can<-matcor(Xmat,Ymat)
Corr_can
img.matcor(Corr_can,type = 2)

Corr_can2<-cc(Xmat,Ymat)
Corr_can2
Corr_can2$cor #Correlaciones canonicas
Corr_can2[3:4] #Coeficientes canonicos
plt.cc(Corr_can2,var.label = T)

cargas_canonicas<-comput(Xmat,Ymat,Corr_can2)
cargas_canonicas[3:6]

?p.asym
p.asym((Corr_can2$cor),(dim(Xmat)[1]),(length(Xmat)),(length(Ymat)),tst
at = "Wilks")
p.asym((Corr_can2$cor),(dim(Xmat)[1]),(length(Xmat)),(length(Ymat)),tst
at = "Hotelling")
p.asym((Corr_can2$cor),(dim(Xmat)[1]),(length(Xmat)),(length(Ymat)),tst
at
"Pillai")p.asym((Corr_can2$cor),(dim(Xmat)[1]),(length(Xmat)),(length(Y
mat)),tstat = "Roy")

?cca #Libreria vegan
Corr_can3<-cca(Xmat,Ymat)
Corr_can3
plot(Corr_can3)

?CCorA
Corr_can4<-CCorA(Ymat,Xmat)
Corr_can4
Corr_can4$CanCorr
biplot(Corr_can4)

#5. PLS

#Datos de entrenamiento y validacion
set.seed(12345)
indice<-createDataPartition(datos$Poblacion,p=0.75,list = FALSE,times =
1)
datos_entrenam<-datos[indice,]
datos_validac<-datos[-indice,]
View(datos_entrenam)
View(datos_validac)

Xmat_entrenamiento<-datos_entrenam[,2:6]
Xmat_entrenamiento<-as.matrix(Xmat_entrenamiento)
```

```
View(Xmat_entrenamiento)

Ymat_entrenamiento<-datos_entrenam[,7:11]
Ymat_entrenamiento<-as.matrix(Ymat_entrenamiento)
View(Ymat_entrenamiento)

#Modelo plsr
?plsr
plsFit = plsr(Ymat_entrenamiento~Xmat_entrenamiento,
validation="CV",scale=TRUE,model=TRUE)
summary(plsFit)
class(plsFit)
plsFit$coefficients

plot(RMSEP(plsFit),main="Raiz del error para el modelo PLS")
plot(plsFit, plottype='coef',labels=names(datos_entrenam), ncomp=1:5)
plot(plsFit,plottype="correlation",
labels=names(datos_entrenam),cex=0.6)

pred_plsr
=predict(plsFit,ncomp=5,newdata=as.matrix(datos_validac[,2:6]))
sum((datos_validac[,7:11]-pred_plsr)^2)

# 6. Agrupamiento jerarquico

datos_escalados<-scale(datos)
d=dist(datos_escalados,method = "euclidian")
clus1<-hclust(d,method = "ward.D2")
subgrups <- cutree(clus1, k = 5)
table(datos$Poblacion,as.factor(subgrups))

#kmeans
res.hk <-hkmeans(datos_escalados, 5)
paleta<-c("#046e6c","#fbb29e","#80c1c5","#800080","#926343")
fviz_cluster(res.hk,ggtheme = theme_minimal(),palette=paleta)

paleta_ordenada<-c("#80c1c5","#046e6c","#926343","#fbb29e","#800080")
# dendrograma
fviz_dend(res.hk, cex = 0.6, rect = TRUE, rect_fill = TRUE,palette =
paleta_ordenada,rect_border = paleta_ordenada)
```

CASO 3

Del artículo: “Factor analysis of the utilization and ownership structure of agricultural land areas in Romania”

El propósito de este artículo es clasificar los condados de Rumania según las principales variables que caracterizan las estructuras agrarias a través de métodos específicos, como el análisis factorial y el análisis de conglomerados. Los trabajos de investigación identificaron seis conglomerados con características similares que delimitan el perfil agrícola rumano.

- Reproducir el análisis del artículo FA y realice análisis adicionales que considere pertinentes para explicar los resultados.
- Adjunte gráficos de fa y verifique supuestos

1. Descripción del estudio

Los trabajos de investigación del aprovechamiento y tenencia de la tierra se basaron en los datos suministrados a nivel de condado por una encuesta de 2013. Inicialmente se tenía planeado generar dos análisis factoriales tomando por separado la estructura del área agrícola por el método de utilización de la tierra y la estructura del área agrícola por formas de propiedad. Sin embargo, la prueba KMO ejecutada para el conjunto de datos de utilización de la tierra fue menor a 0.5, lo que sugería que el análisis factorial era inaceptable al no existir correlaciones superiores a 0.3 dentro de las variables analizadas.

Lo anterior condujo a la creación de un modelo único de PCA basado en seis variables, a partir de las cuales se basó el análisis factorial. Los datos de esas variables fueron estandarizados, obteniendo el valor de puntaje Z ($z_1 \dots z_6$) y posteriormente se aplicó la traducción de Hull ($Var_i = 14 * Z_i + 50$) para generar las variables a utilizar para el análisis factorial ($Var_1 \dots Var_6$) (Tabla 22).

Tabla 22. Descripción de las variables.

Variable	Descripción
Var_1	Porción de tierra cultivable en UAA
Var_2	Proporción de pastos y campos de heno en UAA
Var_3	Porción de cultivos permanentes en UAA
Var_4	Porción de participación arrendada de UAA
Var_5	Participación de UAA en propiedad en total UAA
Var_6	Proporción de UAA propiedad de unidades con personalidad jurídica en total UAA

2. Comprobación de supuestos

Normalidad de las variables

Se utilizó la prueba de Shapiro-Test para verificar el supuesto de normalidad de las variables $Var_1 \dots Var_6$. Las primeras cinco variables presentaron valores p mayores a 0.05, lo que indica que la distribución de los datos no es significativamente diferente a una distribución normal, en otras palabras, se cumple el supuesto de normalidad. La última variable no cumplió con dicho supuesto con un valor de p de 0.00044.

Correlación entre variables

Se obtuvo la matriz de correlaciones entre las variables $Var_1 \dots Var_6$ (Tabla 23). Se observa que únicamente la Variable 6 presentó menores correlaciones con el resto de las variables con valores menores a 0.1.

Tabla 23. Matriz de correlaciones entre variables.

	Var1	Var 2	Var3	Var4	Var5	Var6
Var1	1.000					
Var2	-0.973	1.000				
Var3	0.830	-0.829	1.000			
Var4	0.860	-0.838	0.663	1.000		
Var5	-0.841	0.821	-0.628	-0.995	1.000	
Var6	-0.179	0.164	-0.311	-0.029	-0.066	1.000

Prueba KMO

La prueba KMO fue realizada únicamente para el conjunto de datos que contenía las variables $Var_1 \dots Var_6$. Para ello, se utilizó la función *KMO* del paquete *psych*. El valor obtenido fue de 0.63, igual al reportado por Toma y Dobre (2016).

Prueba de Bartlett.

La prueba de esfericidad de Bartlett permite verificar si la reducción de dimensiones es posible y fue obtenida con la función *cortest.bartlett* del paquete *psych*. Para su cálculo se utilizó la matriz de correlaciones y se especificó un valor de $n = 40$, que es total de condados evaluados. La hipótesis nula es que la reducción de dimensiones no es posible, por lo que se espera un valor de p menor a 0.05 que sugiera lo contrario. Se obtuvo un valor de chi-cuadrada de 491.9152 con 15 grados de libertad y un valor de significancia p de 2.897428e-95, muy similar al obtenido en SAS por los autores.

Gráfica de sedimentación

Se realizó una exploración para la extracción de factores mediante la construcción de la gráfica de sedimentación (obtenida con la función *scree* del paquete *psych*). Esta primera exploración sugiere que se requieren, al menos, la extracción dos componentes (Figura 21).




Figura 21. Gráfica de sedimentación para la extracción de componentes.

3. Extracción de componentes principales

Se realizó una extracción de componentes principales utilizando la función *prcomp* del paquete *stats* y la función *PCA* del paquete *FactoMine*, Utilizan la descomposición de valores singulares (la descomposición de valores singulares examina covarianzas/correlaciones entre individuos). La importancia de los componentes y sus respectivos eigenvalores se muestran en la Tabla 24. Los eigenvalores encontrados fueron ligeramente diferentes a los reportados por los autores mediante SAS por un par de unidades, sin embargo, el % de varianza y el % de varianza acumulada fue similar. Se observa que con dos componentes el porcentaje de varianza acumulada supera el 90%.

Tabla 24. Eigenvalores e importancia de los componentes PCA.

	PC1	PC2	PC3	PC4	PC5	PC6
Eigenvalores	829.897	213.598	69.439	28.681	4.946	0.034
Desviación estándar	29.1749	14.8012	8.4392	5.4237	2.2523	0.1882
Proporción de varianza (%)	72.379	18.628	06.0561	02.5014	0.4313	0.0030
Proporción acumulada (%)	72.38	91.01	97.06	99.56	99.99	100.00

En la Figura 21 se observa que las variables más correlacionadas positivamente son la Var1, Var 3 y Var4, mientras que las variables Var2 y Var5 muestran cierto grado de correlación. Como era de esperarse, la variable Var6 presenta otra dimensionalidad.




Figura 22. Gráfico de afinidad de las variables en el componente 1 y 2.

4. Extracción de factores

Un análisis factorial aborda la extracción de datos de forma diferente a PCA, también busca reducir las dimensiones en los conjuntos de datos a partir de la correlación lineal que exista entre ellos. En PCA, no se realiza una distinción entre dos tipos de varianza (común y única), sino que se centra en la varianza total. Una vez verificados los supuestos requeridos para el

análisis factorial, se utilizó la función *principal* del paquete *psych* para la extracción de los factores. La importancia de los componentes y sus respectivos eigenvalores se muestran en la Tabla 25. Los valores son muy similares a los obtenidos por PCA y los reportados por Toma y Dobre (2016). El primer factor explica el 72% de la varianza total y el segundo factor 18.6%.

Tabla 25. Eigenvalores e importancia de los factores.

	PC1	PC2	PC3	PC4	PC5	PC6
Eigenvalores	829.897	213.598	69.439	28.681	4.946	0.034
Desviación estándar	4.343	1.118	0.363	0.150	0.026	0.000
Proporción de varianza (%)	72.40	18.628	06.1	2.50	0.43	0.003
Proporción acumulada (%)	72.38	91.01	97.06	99.56	99.99	100.00

Observamos que las cargas de los componentes se agrupan en los primeros dos componentes (Figura 23). Una vez que se obtiene una solución inicial, se rotan las cargas. La rotación de factores se utiliza para aumentar la interpretabilidad.




Figura 23. Relación entre variables y factores.

5. Selección de un método de rotación

La rotación es una forma de minimizar las cargas bajas y maximizar las altas de tal forma que la estructura se pueda simplificar lo más posible. La rotación ortogonal (varimax) permite que los factores rotados permanezcan sin correlación, mientras que, en la rotación oblicua, los factores estarán correlacionados. Asumiendo que no existe correlación entre los factores extraídos, se realizó una rotación utilizando el método *varimax*. En esta ocasión solo se

utilizaron los dos primeros factores. Para la rotación oblicua, se utilizó en conjunto, la librería *PGARotation*. La comunalidad entre los factores no rotados, factores rotados ortogonalmente y factores rotados oblicuamente son similares a los reportados por los autores (Tabla 26).

Tabla 26. Valores de comunalidad obtenidos en la extracción de factores.

	Var1	Var2	Var3	Var4	Var5	Var6
PCA	1	1	1	1	1	1
Rotación ortogonal	0.9468	0.9273	0.8045	0.9171	0.9287	0.9357
Rotación oblicua	0.9468	0.9273	0.8045	0.9171	0.9287	0.9357

Tal como los autores indican, el análisis de comunalidades obtenido del análisis factorial sin rotación inicialmente fue de 100% de la varianza debido a las correlaciones en la base de datos. Sin embargo, al rotar los factores, estos explican el 94% de la varianza de Var1, 93% de la varianza de Var6, 92% de la varianza de Var2, Var4 y Var5 y aproximadamente el 80% de la variable Var4. En la Tabla 27 y Tabla 28 se muestra el porcentaje de varianza explicada para rotación y sus respectivas cargas. En este caso, parece ser más apropiada la rotación ortogonal al explicar con dos factores el 91.1% de la varianza. Por orden de importancia, se tiene el siguiente orden de variables (Ecuación 1):

$$Var1 \rightarrow Var4 \rightarrow Var3 \rightarrow Var5 \rightarrow Var2 \rightarrow Var6 \quad (1)$$

En la Figura 24 se observa como el orden de las variables cambia entre los diferentes métodos de rotación.

Tabla 27. Importancia de los factores rotados.

	Rotación ortogonal		Rotación oblicua	
	RC1	RC2	TC1	TC2
Cargas SS	4.278	1.18	4.292	1.146
Proporción de varianza	71.3	19.7	71.5	19.1
Varianza acumulada	71.9	91.1	71.5	90.6

Tabla 28. Cargas obtenidas en la extracción de factores rotados.

	Rotación ortogonal		Rotación oblicua	
	RC1	RC2	TC1	TC2
Var1	0.957	-0.175	0.956	-0.106
Var2	-0.948	0.170	-0.947	0.103
Var3	0.806	-0.394	0.797	-0.337
Var4	0.955		0.962	0.141
Var5	-0.949	-0.166	-0.960	-0.235
Var6		0.967		0.967

Por lo anterior, la Ecuación 2, 3 y 4 se indica los factores finales respecto a la clasificación de condados de Rumania:

$$AI \text{ structure UAA} = \text{Factor1} + \text{Factor2} \quad (2)$$

Donde:

$$\text{Factor1} = 0.957 * \text{Var1} + 0.955 * \text{Var4} + 0.806 * \text{Var3} - 0.949 * \text{Var5} - 0.948 * \text{Var2} \quad (3)$$

$$\text{Factor2} = 0.967 * \text{Var6} \quad (4)$$




Figura 24. Relación entre variables y factores rotados bajo el método ortogonal y oblicuo, respectivamente.

6. Clasificación de los condados

Para la obtención de los condados se resolvieron las ecuaciones y el valor final fue ordenado de mayor a menor. Para ello, se utilizó la función *arrange* del paquete *dplyr*. La clasificación final de los condados de muestra en la Tabla 29. los valores obtenidos fueron iguales a los reportados por los autores, mismos que recalcan que los condados con valores más altos tienen la producción agrícola como principal perfil productivo, con altas tasas de superficie arrendadas y utilizadas por unidades agrícolas. Los últimos lugares cuentan con un perfil principal de producción ganadera, con alta proporción de pastos y campos de heno y altos valores de propiedad de la tierra.

Tabla 29. Clasificación de condados por agregación sobre la base de factores.

Condado	Factor1	Factor2	AI Structure UAA	Condado	Factor1	Factor2	AI Structure UAA
Călărași	158.52	38.03	196.56	Argeș	16.53	73.25	89.78
Ialomița	147.43	37.38	184.81	Neamț	44.51	35.06	79.57
Constanța	134.54	43.61	178.15	Bihor	38.6	40.34	78.93
Galați	116.54	57.24	173.78	Bacău	21.23	50.6	71.83
Teleorman	132.63	39.31	171.94	Mehedinți	9.27	56.76	66.03
Brăila	120.52	39.26	159.78	Vâlcea	-29.02	79.16	50.15
Giurgiu	113.9	41.21	155.11	Mureș	10.16	39.39	49.54
Vaslui	93.26	61.31	154.57	Alba	4.59	43.88	48.47
Tulcea	108.46	43.69	152.16	Sălaj	-12.76	58.19	45.43
Olt	91.63	48.07	139.7	Sibiu	-4.22	39.76	35.54
Timiș	89.96	39.57	129.53	Caras-Severin	-16.7	49.27	32.57
Iași	76.03	52.85	128.88	Brașov	-1.42	33.93	32.51
Vrancea	34.91	93.83	128.74	Covasna	-5.43	33.34	27.91
Buzău	66.39	57.75	124.14	Gorj	-33.42	59.31	25.89
Dolj	72.49	47.67	120.16	Cluj	-15.88	38.96	23.08
Arad	71.57	39.06	110.63	Suceava	-18.43	36.63	18.19
Satu Mare	53.98	52.69	106.67	Hunedoara	-33	35.14	2.14
Prahova	41.57	64.85	106.43	Bistrița-Năsăud	-47.86	47.71	-0.14
Botoșani	65.75	36.61	102.36	Maramureș	-59.24	51.82	-7.42
Dâmbovița	29.53	64.89	94.42	Harghita	-45.13	32.63	-12.51

7. Agrupamiento Kmeans

Los autores no especifican los parámetros bajo los cuales se obtuvo el agrupamiento por el método *kmeans*, por ejemplo, el número de iteraciones máximas o si los datos fueron nuevamente escalados, la medición de distancia utilizada o el método de agrupación. En este sentido, se utilizaron los parámetros establecidos por defecto en la función *hkmeans* de la librería *factoextra* y se definieron seis grupos. En la Tabla 30 se muestran los condados agrupados por este método. Adicionalmente, en la Figura 25 y la Figura 26 se muestra el dendrograma y los clusters obtenidos.

Tabla 30. Agrupamiento por el método kmeans.

	1	2	3	4	5	6
AI Structure	171.5346	126.2407	105.2055	74.0901	35.3887	-4.4863
Factor1 scores	129.0700	78.3814	35.3030	28.3994	-11.1415	-46.3115
Factor2 scores	42.4646	47.8592	69.9025	45.6907	46.5302	41.8251
No. condados	8	8	5	4	11	4
Condados	Călărași Ialomița Constanța Galați Teleorman Brăila Giurgiu Tulcea	Vaslui Olt Timiș Iași Buzău Dolj Arad Botoșani	Vrancea Satu Mare Prahova Dâmbovița Argeș	Neamț Bihor Bacău Mehedinți	Vâlcea Mureș Alba Sălaj Sibiu Caras- Severin Brașov Covasna Gorj Cluj Suceava	Hunedoara Bistrița- Năsăud Maramureș Harghita




Figura 25. Dendrograma obtenido por el método de agrupación kmeans.




Figura 26. Clusters obtenidos por el método kmeans.

8. Determinación de clústeres óptimos

Para calcular cuantos clústeres son óptimos se puede utilizar el método de suma de cuadrados *wss* y el método de silueta promedio *silhouette*. Se utilizó la función *nviz_nbclust* de la librería *factoextra*. Para encontrar el “k” óptimo bajo este método se crea el diagrama del codo, donde se estima el total de la suma total de cuadrados dentro del clúster para diferentes valores de “k”. Luego, visualmente se identifica un punto donde aparezca una caída muy fuerte seguida de una caída más gradual de la pendiente. La Figura 27 muestra que un valor de *k* entre 4 a 6 es adecuado para la agrupación, por lo cual, se asume que fue correcta la agrupación utilizando seis grupos.




Figura 27. Número óptimo de clusters con el método de mínimos cuadrados.

Con el análisis de siluetas se mide la calidad de una agrupación. Es decir, se determina qué tan bien se encuentra cada objeto dentro de su grupo. Un alto ancho de silueta promedio indica un buen agrupamiento. El método de la silueta promedio calcula la silueta promedio de las observaciones para diferentes valores de “k”. El número óptimo de grupos “k” es el que maximiza la silueta promedio en un rango de valores posibles para “k”. En este caso, se observa que con dos grupos es suficiente para el análisis anterior (Figura 28).




Figura 28. Número óptimo de clusters con el método de silueta.

9. Código en R

```
#Conjunto de datos
rm(list=ls())
setwd("C:/Users/zaira/Documents/01 - Doctorado PCF/Otoño 2020/Análisis
multivariado/Examen/Rscripts")
datos<-read.csv("datos problema3.csv",header=TRUE)
View(datos)
options(max.print = 10000)

#Librerías
library(psych)
library(factoextra)
library(FactoMineR)
library(GPArotation)
library(psy)
library(dplyr)

names(datos)
datos_var<-datos[,8:13] #Hull transformacion, los datos proporcionados
ya estan escalados

## 1. Comprobación de supuestos
#Prueba de normalidad
shapiro.test(datos_var$Var1) #Es normal
shapiro.test(datos_var$Var2) #Es normal
shapiro.test(datos_var$Var3) #Es normal
shapiro.test(datos_var$Var4) #Es normal
shapiro.test(datos_var$Var5) #Es normal
shapiro.test(datos_var$Var6) #No es normal

#Matriz de correlaciones
correlaciones<-cor(datos_var)
round(correlaciones,3)
covarianzas<-cov(datos[,2:7])

#Medida de adecuación KMO
KMO(datos_var)

#Prueba de bartlett
cortest.bartlett(correlaciones,length(datos$Var1),diag = FALSE)

#Grafica de sedimentacion
scree(datos_var,factors=TRUE)

#2. Extracción de componentes por PCA
#Nota: Las variables utilizadas ya estaban previamente escaladas por los
autores
?prcomp
Compon<-prcomp(datos_var,scale. = FALSE)
summary(Compon)
Compon
Compon$sdev
Compon$x
biplot(Compon,scale=0)

?PCA
comp2<-PCA(datos_var,scale=FALSE,ncp=6)
comp2$eig
fviz_screplot(comp2,addlabels=FALSE,geom="line")
plot(comp2,choix = "ind",cex=0.7)
plot.PCA(comp2,axes=c(1,2),choix = "var",habillage = 2,cex=0.7,ellipse =
TRUE)
paleta<-c("#451460","#56b893","#a9c12a")
fviz_pca_var(comp2,col.var = "cos2",gradient.cols=paleta,repel=TRUE)
```

#3. Extracción de factores sin rotación

```
facts1<-principal(datos_var,nfactors = 6,rotate = "none")
summary(facts1)
print(facts1,digits = 3)
facts1$loadings
facts1$communality
facts1$values
facts1$scores

f1<-facts1$scores[,1]
f2<-facts1$scores[,2]
plot(f1,f2)

fa.diagram(facts1,labels = names(datos_var))
plot(facts1$values, type = "b",xlab = "Factors", ylab = "Eigen values",
main = "SCREE PLOT")

#Ajuste del modelo
factor.fit(correlaciones,facts1$loadings[,1:2])      #considerando      2
componentes
```

4. Rotación de factores

```
#Rotación ortogonal
facts_Rotados<-principal(datos_var,nfactors = 2,rotate = "varimax")
summary(facts_Rotados)
print(facts_Rotados,digits = 3)
facts_Rotados$loadings
facts_Rotados$communality
facts_Rotados$values
facts_Rotados$scores
fa.diagram(facts_Rotados,labels = names(datos_var))

#Rotación oblicua
facts_Rotados2<-principal(datos_var,nfactors = 2,rotate = "oblimin")
print(facts_Rotados2,digits = 3)
facts_Rotados2$loadings
facts_Rotados2$communality
facts_Rotados2$values
facts_Rotados2$scores
fa.diagram(facts_Rotados2,labels = names(datos_var))

#Comparación de comunialidades
facts1$communality
facts_Rotados$communality
facts_Rotados2$communality
```

#5. Obtención de factores (AI Structure)

```
#Sustituir en la ecuación
#0.957*Var1+0.955*Var4+0.806*Var3-0.949*Var5-0.948*Var2
Factor1<-
(0.957*datos_var$Var1)+(0.955*datos_var$Var4)+(0.806*datos_var$Var3)-
(0.949*datos_var$Var5)-(0.948*datos_var$Var2)
Factor2<-0.967*(datos_var$Var6)
AI_structure<-Factor1+Factor2

AI_Structure_Rumania<-
data.frame(datos$Counties,Factor1,Factor2,AI_structure)
View(AI_Structure_Rumania)
?arrange
AI_Structure_Rumania_Ordenada<-
arrange(AI_Structure_Rumania,desc(AI_structure))
AI_Structure_Rumania_Ordenada
```

```
#6. Kmeans
set.seed(101010)

?hkmeans()
paleta<-c("#046e6c","#fbb29e","#80c1c5","#800080","#926343","#3b7d5c")
res.hk<-hkmeans(AI_Structure_Rumania_Ordenada[,2:4],6)
res.hk
res.hk$cluster
res.hk$size
fviz_cluster(res.hk,ggtheme = theme_minimal(),palette=paleta)

paleta_ordenada<-
c("#fbb29e","#046e6c","#3b7d5c","#926343","#80c1c5","#800080")
# dendrograma
fviz_dend(res.hk, cex = 0.6, rect = TRUE, rect_fill = TRUE,palette =
paleta_ordenada,rect_border = paleta_ordenada)

#Agrupamiento jerarquico
d=dist(AI_Structure_Rumania_Ordenada,method = "euclidian")
clus1<-hclust(d,method = "ward.D2")
subgrups <- cutree(clus1, k = 6)
clus1
subgrups
table(AI_Structure_Rumania_Ordenada$datos.Counties,as.factor(subgrups))

#7. Numero optimo de clusteres
fviz_nbclust(AI_Structure_Rumania_Ordenada[,2:4], FUN = kmeans, method =
"wss")
fviz_nbclust(AI_Structure_Rumania_Ordenada[,2:4], FUN = kmeans, method =
"silhouette")
```